

## گزارش پیشرفت: فاز ۲ پروژه

### ۱. معرفی اولیه مجموعه داده و تعریف مسئله

مسئله پیش‌رو یک پروژه **Multi-class Classification** است که در آن هدف اصلی، پیش‌بینی صحیح کلاس متغیر هدف گسسته به نام  $y$  می‌باشد. این متغیر شامل ۴ کلاس مجزا (کلاس‌های ۱، ۲، ۳ و ۴) است که وضعیت نهایی یک رخداد ثبت‌شده در سامانه را توصیف می‌کند.


مجموعه داده ورودی شامل ویژگی‌هایی نام‌گذاری شده از قبیل  $f_1$  تا  $f_{34}$  است. تمام تحلیل‌های انجام‌شده در این مرحله صرفاً بر پایه رفتار ساختاری، آماری و محاسباتی خود داده‌ها استوار است.

### ۲. بررسی اولیه داده‌ها و تحلیل اکتشافی (EDA)

برای شناخت ساختار توزیع ماتریس ویژگی‌ها و متغیر هدف، بررسی‌های آماری اولیه روی داده‌های خام صورت گرفت تا میزان توازن کلاس‌ها و کیفیت داده‌های عددی ورودی ارزیابی شود.

الف) توزیع متغیر هدف ( $y$ )

بررسی توزیع کلاس‌های چهارگانه نشان می‌دهد که مجموعه داده دچار چالش **Class Imbalance** است. بیش از ۴۵ درصد از نمونه‌ها به یک کلاس خاص اختصاص دارند، در حالی که دسته‌های ۳ و ۴ کمترین سهم از فراوانی را دارا هستند. این عدم توازن نقشی تعیین‌کننده در فازهای بعدی ایفا خواهد کرد؛ چرا که مدل‌های آماری به طور طبیعی تمایل دارند به سمت کلاس اکثریت سوگیری داشته باشند.




ب) تحلیل نرخ داده‌های مفقود (Missing Values)

پیش از آغاز هرگونه فرآیند اصلاح، یک ارزیابی ساختاری روی درصد فیلدهای پوچ (Null) در تمامی ویژگی‌ها انجام شد. نتایج آماری نشان داد که توزیع داده‌های مفقود در سراسر ماتریس به هیچ وجه یکنواخت نیست. بخش بزرگی از مجموعه داده در سلامت کامل عددی قرار دارد، در حالی که چند ستون متمایز، نرخ گمشدگی بالای ۲۵ درصد را ثبت کرده‌اند که فرآیند تصمیم‌گیری آماری درباره آن‌ها در بخش پیش‌پردازش مستند شده است.

### ۳. کارهای انجام‌شده در زمینه پاک‌سازی و پیش‌پردازش داده‌ها

بر اساس خروجی‌های به‌دست آمده از بخش تحلیل اکتشافی، یک Pipeline پیش‌پردازش متمرکز و چندمرحله‌ای طراحی و روی ماتریس ویژگی‌ها اعمال شد تا سازگاری داده‌ها با معیارهای ریاضی یادگیری ماشین تضمین شود:

- **حذف ستون‌های با نرخ گمشدگی بالا:** ستون‌های عددی  $f_{20}$ ,  $f_{14}$ ,  $f_5$  به دلیل دارا بودن نرخ مفقودی بالا و ثبت فیلدهای پوچ بالای ۲۵٪، به‌طور کامل از ماتریس ویژگی‌ها کنار گذاشته شدند. از آنجا که حجم اطلاعات موجود در این ستون‌ها ناچیز بود، هرگونه تلاش برای بازسازی یا Imputation داده‌ها منجر به تزریق نویز شدید و سوگیری‌های مصنوعی در الگوریتم می‌شد.
- **جایگذاری مقادیر مفقود:** در سایر ستون‌های عددی باقی‌مانده که نرخ داده‌های گمشده آن‌ها بسیار ناچیز و در حد چند درصد بود، راهبرد جایگذاری با Mean همان ستون اعمال شد تا ساختار ابعادی ردیف‌ها و حجم کلی نمونه‌های در دسترس حفظ شود. حالا که مقادیر عددی کاملاً پر شده‌اند تنها ستون‌های مقادیر خالی غیرعددی به جای میمانند که سرجمع در ۳٪ رکورد های داده‌ها وجود دارند، به دلیل ناچیز بودن این مقدار بهتر بود که از این سطر ها صرف نظر کنیم.
- **حذف ویژگی‌های متنی اضافه و ثابت:** ستون  $f_{11}$  از Pipeline محاسباتی کنار گذاشته شد چون تنها دارای مقدار US بود. ویژگی‌های بدون واریانس توانایی تفکیک‌کنندگی ندارند و نگهداری آن‌ها تنها باعث افزایش بیهوده ابعاد مسئله می‌شود. همچنین ستون های  $f_8$ ,  $f_7$  کنار گذاشته شدند چون این مقادیر متنی غیرساختاریافته تنها با روش های LLM, NLP قابل استفاده اطلاعاتی هستند که در این درس مورد بحث نیستند.
- **استخراج ویژگی‌های زمانی:** به‌منظور تبدیل اطلاعات متنی موجود در ستون‌های  $f_{21}$  و  $f_{22}$  به ویژگی‌های عددی قابل استفاده، ویژگی‌های زمانی `season`, `duration_min`, `hour`, `day_of_week` از این ستون‌ها استخراج شدند. علاوه بر این، میزان ارتباط و تأثیر هر یک از این ویژگی‌های استخراج‌شده بر متغیر هدف نیز مورد بررسی قرار گرفت تا تنها ویژگی‌های مؤثر و معنادار در فرآیند مدل‌سازی مورد استفاده قرار گیرند.
- **نحوه حذف ستون‌های شرایط زمانی دوگانه:** ستون‌های پایانی مجموعه داده شامل  $f_{34}$ ,  $f_{33}$ ,  $f_{32}$ ,  $f_{31}$  که مربوط به موقعیت‌های زمانی شب و روز در شرایط مختلف بودند، به‌طور کامل حذف شدند. با بررسی ماتریس همبستگی مشخص شد که این چهار ستون Multicollinearity شدید و تداخل اطلاعاتی کاملی با سایر ویژگی‌های زمانی دارند؛ بنابراین برای جلوگیری از افزونگی داده‌ها و کاهش ابعاد غیرضروری، از Pipeline پردازش کنار گذاشته شدند.



- **کدگذاری ویژگی‌های دسته‌ای:** ستون‌های متنی از نوع categorical بر اساس تعداد مقادیر یکتای خود به دو گروه تقسیم شدند. برای ستون‌هایی با تعداد دسته‌های زیاد، از روش frequency encoding استفاده شد تا ضمن حفظ اطلاعات توزیع داده‌ها، از افزایش بیش از حد ابعاد مجموعه ویژگی‌ها جلوگیری شود. در مقابل، ستون‌هایی با تعداد دسته‌های معقول با استفاده از روش one-hot encoding به ویژگی‌های عددی تبدیل شدند تا مدل بتواند آن‌ها را بدون ایجاد ترتیب مصنوعی میان دسته‌ها پردازش کند.
- **نرمال‌سازی ویژگی‌ها:** به‌منظور یکسان‌سازی مقیاس ویژگی‌های عددی و بهبود فرآیند آموزش مدل، مقادیر ستون‌ها با استفاده از روش StandardScaler از کتابخانه sklearn نرمال‌سازی شدند. در این روش، هر ویژگی بر اساس میانگین و انحراف معیار خود استاندارد شده و به توزیعی با میانگین صفر و انحراف معیار یک تبدیل می‌شود. این کار موجب افزایش پایداری عددی، تسریع همگرایی الگوریتم‌های یادگیری و بهبود عملکرد مدل‌هایی می‌شود که به مقیاس ویژگی‌ها حساس هستند.
- **حذف ردیف‌های تکراری:** ردیف‌های کاملاً مشابه و همسان که فاقد هرگونه ارزش اطلاعاتی جدید بوده و صرفاً باعث Overfitting روی نمونه‌های خاص می‌شدند، شناسایی و از مجموعه داده حذف شدند.

## ۴. مشکلات و ابهامات

- **محدودیت تحلیل شهودی:** پنهان بودن ماهیت ستون‌ها از  $f_1$  تا  $f_{34}$  امکان مهندسی ویژگی‌های کیفی مبتنی بر منطق یا ترکیب شهودی ستون‌ها را سلب کرده است. این امر ما را ناچار می‌سازد تا در مراحل پردازشی کاملاً به روش‌های تغییرات ریاضی، تحلیل‌های آماری پیشرفته و روش‌های خودکار کاهش ابعاد متکی بمانیم.
- **چالش عدم تقارن داده‌ها:** وجود چالش عدم تعادل شدید در متغیر هدف به این معنی است که الگوهای مربوط به کلاس‌های ۳ و ۴ بسیار کمتر در دسترس هستند. این توزیع نامتوازن به عنوان یکی از چالش‌های اصلی ساختاری داده‌های ورودی ثبت شد که در طراحی Pipeline‌های بعدی باید مستقیماً مدیریت شود.